

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH

Viện Công nghệ thông tin và Điện, Điện tử

Môn học: Học kỳ doanh nghiệp

Chat with Your PDF

Hỏi đáp tài liệu PDF tiếng Việt có trích dẫn số trang bằng RAG

Võ Thành Phước


GVHD: ThS. Nguyễn Thanh Tiến

Vấn đề và câu hỏi nghiên cứu

- Tài liệu dài, tra cứu thủ công tốn thời gian
- LLM trả lời trôi chảy nhưng có thể bịa và không chỉ ra nguồn

Chunk theo ranh giới trang có tăng độ chính xác trích dẫn so với fixed-size và long-context không?

Bài toán hỏi đáp tài liệu PDF tiếng Việt có trích dẫn số trang bằng RAG



Cơ sở lý thuyết: 4 kỹ thuật nền tảng

1. RAG (Retrieval-Augmented Generation)

Truy hồi đoạn liên quan từ tài liệu rồi mới cho mô hình sinh câu trả lời, giúp giảm bịa và dùng được tài liệu mới.

Trong đề tài: Hệ thống nhận PDF do người dùng tải lên.

2. Chia đoạn (chunking)

Fixed-size cắt theo độ dài nên có thể cắt ngang ý và trang; semantic theo ý nghĩa; structure-aware theo cấu trúc.

Trong đề tài: Chọn page-aware (theo trang); fixed-size làm đối chứng.

3. Truy hồi lai (hybrid search)

Dense hiểu ngữ nghĩa, BM25 khớp từ khóa, tên riêng và số liệu; hợp nhất hai bảng xếp hạng bằng RRF.

Trong đề tài: Dense (FAISS) + BM25 + RRF, $k = 60$.

4. Trích dẫn và từ chối (abstention)

Trích dẫn có căn cứ để kiểm chứng nguồn; từ chối trả lời khi bằng chứng yếu để tránh suy đoán.

Trong đề tài: Số trang lấy từ metadata; từ chối 2 tầng (ngưỡng cosine, model).

Đặc thù tiếng Việt: chuẩn hóa mã cũ TCVN3/VNI về Unicode, tách từ bằng VnCoreNLP trước khi embedding và BM25.

Dữ liệu đánh giá

9

tệp corpus chính thức

50

câu Test Set độc lập với Dev Set

34 / 16

answerable / unanswerable (4
bridge)

Chuẩn (3)

- Hiến pháp (33 trang)
- Báo cáo Vinamilk (53)
- Lịch sử Đảng (60)

Edge-case (5)


- Scan và mixed-scan
- Mã cũ VNI, TCVN3
- Văn bản mất dấu

Mở rộng (1)

- Word (.docx), ngoài pipeline chính thức

Kiến trúc hệ thống 5 trạm


Luồng dữ liệu tổng thể: từ tải PDF đến câu trả lời và đánh giá



- Hybrid dense + BM25, hợp nhất bằng RRF
- Lọc ngưỡng $\tau = 0,38$ trước khi gọi Gemini
- Không đủ bằng chứng thì từ chối, không suy đoán
- Công nghệ: Gemini, FAISS, VnCoreNLP, Streamlit

Điểm mới: chunk theo ranh giới trang

Tạo chunk theo trang (ví dụ thật: `normal_hienphap_33tr.pdf`, trang 1-2)




- Mỗi chunk giữ số trang gốc
- Bridge nội trang và liên trang giữ ý ở ranh giới
- Model chỉ chọn nguồn; số trang lấy từ metadata của chunk

Demo giao diện


(a) Chưa có tài liệu




(b) Đã xử lý, sẵn sàng hỏi



(c) Hỏi đáp và chip citation



1. Tải PDF (Hiển pháp)
2. Câu có đáp án: chip số trang
3. Câu không có đáp án: từ chối



Thiết lập thực nghiệm

Ba cấu hình so sánh


- **Page-aware (đề xuất):** chia chunk theo trang, có bridge chunk.
- **Fixed-size (đối chứng):** chunk 170 từ, không theo ranh giới trang.
- **Long-context (đối chứng):** không truy hồi, đưa toàn văn kèm nhãn [Trang X].

Bốn chỉ số chính

- **Hit@3:** trang chứa đáp án nằm trong 3 chunk đầu.
- **Citation accuracy:** tỷ lệ citation chỉ đúng trang tham chiếu.
- **False acceptance:** câu không có đáp án mà vẫn trả lời (16 câu).
- **False refusal:** câu có đáp án mà bị từ chối (34 câu).

Cùng điều kiện: cùng model Gemini và cùng bản text sạch, $\tau = 0,38$ dùng chung. Dev Set dùng để chỉnh tham số; Test Set 50 câu chỉ dùng sau khi đã khóa τ , k , kích thước chunk và model.

Kết quả trên Test Set 50 câu



Chỉ số	Page-aware	Fixed-size	Long-context
Hit@3	94,1%	88,2%	n.a.
Citation accuracy	96,9%	87,1%	76,5%
False acceptance	6,2%	6,2%	0,0%
False refusal	5,9%	8,8%	0,0%
Correctness (full)	85,3%	82,4%	97,1%
Token trung bình	4.546	3.012	41.419

Khó khăn kỹ thuật và phân tích lỗi

Khó khăn đã gặp và cách xử lý

- **Thiếu từ điển vi-vocab trên Windows:** tải thủ công; cosine cùng câu hỏi tăng từ 0,62 lên 0,73.
- **Bridge chunk trùng ở trang scan hoặc trống:** chỉ tạo bridge khi cả hai phía có nội dung.
- **Chunk nhỏ làm thiếu ý:** tăng chunk 256 lên 320 token, top-k lên 15; cải thiện 4/8 câu dev khó.
- **Citation hiển thị dư (tới 14 chip trùng):** model trả used_sources, giao diện gộp chip theo trang.

Phân tích lỗi trên Test Set

- **test_18, false refusal:** trang đúng nằm trong top-3 nhưng cosine thấp hơn $\tau = 0,38$ nên bị chặn; đó là đánh đổi của ngưỡng từ chối.
- **test_20, dữ liệu:** PDF rút dấu thanh trong text layer; OCR thử cũng tạo lỗi mới (“phản đế” thành “phản đề”).
- **test_25, false acceptance:** model trả lời một phần (43 giặc lái) thay vì từ chối câu hỏi vượt phạm vi tài liệu.
- **test_41, bridge case:** thiếu ý “8 nhà máy còn lại” ở ranh giới trang 21-22; long-context cite sai trang.

Đánh đổi và giới hạn

Đánh đổi giữa ba cấu hình

≈ 9×

token mỗi câu của long-context so với page-aware (41.419 so với 4.546)

- Long-context: nội dung đúng cao nhất (97,1%) nhưng citation chỉ 76,5%
- Page-aware: citation 96,9%, cân bằng cho yêu cầu cốt lõi là trích dẫn

Giới hạn

- Cỡ mẫu nhỏ: một câu tương ứng khoảng 2,9 điểm phần trăm
- Bảng và biểu đồ trong PDF chưa xử lý triệt để
- Mã VNI và văn bản mất dấu vẫn giảm chất lượng
- Chưa hỗ trợ .docx trong pipeline chính thức

Đóng góp của đề tài

1 Candidate Ranking

Tạo ứng viên gốc, TCVN3, VNI; chấm bằng từ điển và mật độ nguyên âm có dấu, giữ nguyên khi mở hồ.

2 Bridge chunk hai loại

Bridge liên trang (page_range) và nội trang, bổ sung ngữ cảnh tại ranh giới.

3 Hybrid search

Dense + BM25, hợp nhất bằng RRF để có cả ngữ nghĩa lẫn từ khóa.

4 Citation từ metadata

Dùng page_number hoặc page_range; model không tự viết số trang.

5 Abstention hai tầng

Lọc bằng ngưỡng cosine, sau đó model từ chối khi context không đủ.

Kết luận

Chunk theo ranh giới trang cải thiện độ chính xác trích dẫn, trong phạm vi corpus đánh giá

+5,9

điểm Hit@3 so với fixed-size

+9,8

điểm citation so với fixed-size

+20,4

điểm citation so với long-context

Hướng phát triển: OCR bảng và biểu đồ · nhiều tài liệu mỗi phiên · mở rộng Test Set

Xin cảm ơn!

Cảm ơn thầy cô và các bạn đã lắng nghe. Em rất mong nhận được câu hỏi và góp ý.

Võ Thành Phước

GVHD: ThS. Nguyễn Thanh Tiến